


::Czym sa sieci Kohonena?::

Sieci Kohonena są jednym z podstawowych typów sieci samoorganizujących się. Właśnie dzięki zdolności samoorganizacji otwierają się zupełnie nowe możliwości - adaptacja do wcześniej nieznanych danych wejściowych, o których bardzo niewiele wiadomo. Wydaje się to naturalnym sposobem uczenia, który jest używany chociażby w naszych mózgach, którym nikt nie definiuje żadnych wzorców, tylko muszą się one krystalizować w trakcie procesu uczenia, połączonego z normalnym funkcjonowaniem. Sieci Kohonena stanowią synonim całej grupy sieci, w których uczenie odbywa się metodą samoorganizującą typu konkurencyjnego. Polega ona na podawaniu na wejścia sieci sygnałów, a następnie wybraniu w drodze konkurencji zwycięskiego neuronu, który najlepiej odpowiada wektorowi wejściowemu. Dokładny schemat konkurencji i późniejszej modyfikacji wag synaptycznych może mieć różną postać. Wyróżnia się wiele podtypów sieci opartych na konkurencji, które różnią się dokładnym algorytmem samoorganizacji.

::Architektura sieci saorganizującej się::

Bardzo istotną kwestią jest struktura sieci neuronowej. Pojedynczy neuron jest mechanizmem bardzo prostym i przez to niewiele potrafiącym. Dopiero połączenie wielu neuronów ze sobą umożliwia prowadzenie dowolnie skomplikowanych operacji. Ze względu na raczej niewielką wiedzę o faktycznych zasadach funkcjonowania ludzkiego mózgu, powstało wiele różnych architektur, które starają się naśladować budowę i zachowanie poszczególnych fragmentów układu nerwowego. Najczęściej stosuje się w tego typu sieciach architekturę jednokierunkową jednowarstwową. Jest to podyktowane faktem, że wszystkie neurony muszą uczestniczyć w konkurencji na równych prawach. Dlatego każdy z nich musi mieć tyle wejść ile jest wejść całego systemu.



Użyta sieć była siecią o schemacie kwadratowym jak na rysunku o zmiennej liczbie neuronów od 5 do 20.

::Etapy działania::

Funkcjonowanie samoorganizujących się sieci neuronowych odbywa się w trzech etapach:

- konstrukcja
- uczenie
- rozpoznawanie

System, który miałby realizować funkcjonowanie sieci samoorganizującej powinien składać się z kilku podstawowych elementów. Pierwszym z nich jest macierz neuronów pobudzanych przez sygnały wejściowe. Sygnały te powinny opisywać pewne charakterystyczne cechy zjawisk zachodzących w otoczeniu, tak, aby na ich podstawie sieć była w stanie je pogrupować. Informacja o zdarzeniach jest przekładana na bodźce pobudzające neurony. Zbiór sygnałów przekazywanych do każdego neuronu nie musi być identyczny, nawet ich ilość może być różna. Muszą one jednak spełniać pewien warunek, a mianowicie jednoznacznie określać dane zdarzenia.

Kolejną częścią składową sieci jest mechanizm, który dla każdego neuronu określa stopień podobieństwa jego wag do danego sygnału wejściowego oraz wyznacza jednostkę z największym dopasowaniem - zwycięzcę. Obliczenia zaczynamy dla wag równych małym liczbom losowym, przy czym ważne jest, aby nie zachodziła żadna symetria. W trakcie uczenia wagi te są modyfikowane w taki sposób, aby najlepiej odzwierciedlać wewnętrzną strukturę danych wejściowych. Istnieje jednak niebezpieczeństwo, że zwiążą się one z pewnymi wartościami zanim jeszcze grupy zostaną prawidłowo rozpoznane i wtedy trzeba ponawiać uczenie z innymi wagami.

Wreszcie konieczne do przeprowadzenia samoorganizacji jest, aby sieć była wyposażona w zdolność do adaptacji wartości wag neuronu zwycięzcy i jego sąsiadów w zależności od siły, z jaką odpowiedział on na dane wejście. Topologię sieci można w łatwy sposób określić poprzez zdefiniowanie sąsiadów dla każdego neuronu. Załóżmy, że jednostkę, której odpowiedź na dane pobudzenie jest maksymalna, będziemy nazywali "obrazem" tego pobudzenia. Wtedy możemy przyjąć, że sieć jest uporządkowana, jeśli topologiczne relacje między sygnałami wejściowymi i ich obrazami są takie same.

::Algorytm uczenia::

Algorytmem, od którego nazwę wzięła cała klasa sieci są samoorganizujące się mapy Kohonena. Zostały one opisane przez ich twórcę w publikacji "The Self Organising Map". Kohonen zaproponował dwa rodzaje sąsiedztwa: prostokątne i gaussowskie.

$$G(i, x) = \begin{cases} 1 & \text{dla } d(i, w) \leq \lambda \\ 0 & \text{dla } d(i, w) > \lambda \end{cases}$$

$$G(i, x) = \exp\left(-\frac{d^2(i, w)}{2\lambda^2}\right)$$

"lambda" jest promieniem sąsiedztwa, malejącym w czasie.

W użytym algorytmie zastosowano sąsiedztwo prostokątne o promieniu: $\lambda=0$. Natomiast współczynnik uczenia był albo stały przez cały proces uczenia, albo zmieniał się w czasie zgodnie ze wzorem:

$$\eta = \eta_0 * e^{(t/\lambda)}$$

gdzie:

t – iteracja

λ – stała


Współczynnik uczenia: η_0 zmieniał się w granicach [0.5,0.001]

Sieć była uczona przez 100 epok

Źródło: http://galaxy.agh.edu.pl/~vlsi/AI/koho_t/

::Wyniki::

Zależność ilości aktywnych neuronów od zastosowanej metody uczenia



UCZENIE BEZ KOREKCJI:			UCZENIE Z KOREKCJĄ	
NUMER:	liczba neuronów	typ uczenia	liczba neuronów	typ uczenia
1	5	0.5	5	0.5 sLR: 14900
2	5	0.1	5	0.1 sLR: 14900
3	5	0.01	5	0.01 sLR: 14900
4	5	0.001	5	0.001 sLR: 14900
5	8	0.5	8	0.5 sLR: 14900
6	8	0.1	8	0.1 sLR: 14900
7	8	0.01	8	0.01 sLR: 14900
8	8	0.001	8	0.001 sLR: 14900
9	11	0.5	11	0.5 sLR: 14900
10	11	0.1	11	0.1 sLR: 14900
11	11	0.01	11	0.01 sLR: 14900
12	11	0.001	11	0.001 sLR: 14900
13	14	0.5	14	0.5 sLR: 14900
14	14	0.1	14	0.1 sLR: 14900
15	14	0.01	14	0.01 sLR: 14900
16	14	0.001	14	0.001 sLR: 14900
17	17	0.5	17	0.5 sLR: 14900
18	17	0.1	17	0.1 sLR: 14900
19	17	0.01	17	0.01 sLR: 14900
20	17	0.001	17	0.001 sLR: 14900
21	20	0.5	20	0.5 sLR: 14900
22	20	0.1	20	0.1 sLR: 14900
23	20	0.01	20	0.01 sLR: 14900
24	20	0.001	20	0.001 sLR: 14900

::Analiza::

Ogólnie można powiedzieć, że lepiej sprawdziła się sieć w której zastosowano korekcję współczynnika uczenia zgodnie z podanym wcześniej wzorem. Sieć ta szybciej dochodzi do rozgraniczenia odpowiednich rodzajów kwiatów na podgrupy. Żadnej sieci nie udało się uzyskać dokładnego wyniku i ścisłego podziału na wszystkie 3 gatunki kwiatów.

Najlepsze wyniki zostały uzyskane przez sieć o numerach 13 – 20 dla uczenia z korekcją, oraz dla sieci o numerach 21 – 24 dla uczenia bez korekcji. Obu sieciom udało się wyróżnić co najmniej 3 gatunki kwiatów i z małymi błędami podzielić je na dobre grupy. Maksymalny błąd sieci wynosił ok 6%, czyli 9 źle sklasyfikowanych przypadków.

Na podstawie wyników nie udało się stwierdzić jakiegokolwiek wpływu wartości początkowego współczynnika uczenia na wyniki końcowe.

::Wnioski::

- początkowy współczynnik uczenia ma niewielki wpływ na ostateczne wyniki sieci
- najlepiej w klasyfikacji sprawdzały się sieci z większą ilością neuronów
- gatunek *versicolor* jest podobny do gatunku *virginica*
- sieć z korekcją współczynnika uczenia uczy się szybciej i uzyskuje lepsze wyniki i większe zróżnicowanie w podziale na typy danych